




MovieFactory

Search Quality Improvement Platform

Hybrid Movie Search & Search Experiment System

하이브리드 검색 엔진과 검색 품질 분석, 운영 모니터링을 통합한 Search Experiment Platform

발표자

진달래

CX Tech / 서비스 운영 개선

연락처

☎ 010-2654-1025

✉ gauldaldal@gmail.com

🐙 github.com/gauldal

발표 개요

본 발표에서는 검색 품질 개선을 위한 Hybrid Retrieval 시스템과 검색 실험 및 운영 환경 구축 과정을 단계적으로 설명합니다.

각 섹션은 문제 정의부터 솔루션 설계, 평가 결과, 그리고 핵심 학습까지 이어지는 구조로 구성되어 있습니다.

01

Why Search Quality Matters

검색 품질이 중요한 이유와 시스템 설계의 철학

02

Problem

기존 단일 검색 방식의 한계와 분석 부재 문제

03

Solution Overview

MovieFactory의 핵심 구성 요소 소개

04

Hybrid Retrieval Pipeline

다중 검색 모델 결합 파이프라인 구조

05

Query Lab & Quality Monitor

검색 실험 도구 및 운영 대시보드

06

Search Evaluation & Learnings

평가 지표 결과 및 프로젝트를 통해 얻은 인사이트

Why Search Quality Matters

검색 시스템은 단순히 결과를 반환하는 기능이 아닙니다. 검색 결과의 품질과 랭킹 구조는 사용자 경험에 직접적인 영향을 미치며, 잘못된 랭킹은 사용자 이탈과 신뢰 저하로 이어집니다. 그러나 많은 시스템에서 이 품질을 체계적으로 측정하고 개선하는 환경이 갖춰져 있지 않습니다.

품질 평가의 어려움

검색 결과 품질을 객관적으로 평가할 수 있는 기준과 도구가 없으면, 개선 작업이 주관적 판단에 의존하게 됩니다. 어떤 결과가 "좋은" 결과인지 정량화하기 어렵습니다.

모델 변경 시 품질 추적 불가

검색 모델을 교체하거나 파라미터를 변경했을 때 품질이 향상됐는지, 저하됐는지 확인하는 체계적인 방법이 없으면 실험이 불가능합니다.

랭킹 설명 불가능성

특정 영화가 왜 상위에 랭크되었는지 이유를 설명할 수 없다면, 문제 발생 시 디버깅이 어렵고 사용자 신뢰를 얻기도 힘듭니다.

Search Quality Analysis

검색 결과의 품질을 정량적 지표로 측정하고 분석하는 구조

Search Experimentation


알고리즘 변경의 효과를 실험적으로 검증할 수 있는 환경

Search Operations Monitoring

실시간 운영 지표를 추적하고 이상 징후를 감지하는 모니터링 체계

Problem

기존 영화 검색 시스템은 보통 하나의 검색 방식에만 의존합니다. 각각의 방식은 고유한 강점을 가지지만, 단독으로는 사용자의 다양하고 복잡한 검색 의도를 완전히 충족시킬 수 없습니다. 이러한 단일 방식의 한계는 검색 품질 저하로 직결됩니다.



키워드 검색의 한계

정확한 단어 매칭에는 강하지만, 유사한 의미를 가진 다른 표현이나 문맥적 연관성을 반영하지 못합니다. "슬픈 영화"를 입력해도 감성적인 드라마를 찾지 못할 수 있습니다.



의미 검색의 한계

문맥과 의미 기반 유사도는 우수하지만, 고유명사나 정확한 제목 매칭에서 실패할 수 있습니다. "어벤저스"를 검색했을 때 정확한 타이틀 매칭보다 의미적으로 유사한 결과가 우선될 수 있습니다.



이미지 검색의 한계

시각적 유사도는 포착하지만, 서사적·감정적 연관성을 반영하기 어렵습니다. 포스터 이미지가 비슷해도 내용이 전혀 다른 영화를 반환할 수 있습니다.

? 왜 이 영화가 1위인가?

랭킹 생성 이유를 설명하고 디버깅할 수 있는 도구가 없습니다.

? 모델 변경 후 품질은?

검색 알고리즘 변경 후 품질 변화를 체계적으로 추적할 방법이 없습니다.

MovieFactory Solution

MovieFactory는 검색 품질 개선을 위해 설계된 통합 Search Experiment Platform입니다. 단순히 검색 기능을 제공하는 것을 넘어, 검색 품질을 분석하고, 실험하고, 모니터링하는 전체 라이프사이클을 지원합니다. 네 가지 핵심 구성 요소가 유기적으로 연동되어 동작합니다.



Hybrid Retrieval Engine

CLIP, SBERT 등 서로 다른 검색 모델을 결합하여 각 방식의 강점을 극대화하고 검색 품질을 전반적으로 향상시킵니다. Reciprocal Rank Fusion을 통해 안정적인 최종 랭킹을 생성합니다.



Query Lab

검색 결과 랭킹 구조를 단계별로 분석하고, 알고리즘 변경 효과를 실험할 수 있는 인터랙티브 도구입니다. Engine Contribution 분석과 Ablation 실험을 지원합니다.



Quality Monitor

Streamlit 기반의 Search Operations Dashboard로, 검색 실험 결과, 레이턴시, 검색 결과 수, KPI를 하나의 인터페이스에서 통합 관리합니다.




Search Evaluation Framework

Intent Query 기반의 체계적인 평가 파이프라인으로 Hit@K, Mean Rank 등의 지표를 통해 검색 품질을 정량적으로 검증합니다.

Hybrid Retrieval Engine

Hybrid Retrieval Pipeline은 이미지 쿼리부터 최종 랭킹 생성까지 다양한 검색 모델을 단계적으로 결합하는 구조입니다. 각 단계는 독립적으로 교체 가능하며, 실험을 통해 최적의 조합을 찾을 수 있도록 설계되었습니다.

파이프라인 단계



핵심 설계 원칙

다중 모델 결합

CLIP(시각 임베딩)과 SBERT(의미 임베딩)를 결합함으로써 키워드 기반 검색이 놓치는 의미적 유사성과 이미지 기반 검색의 서사적 한계를 동시에 보완합니다.

Candidate Pool 전략

각 검색 엔진의 결과를 독립적으로 수집한 후 합집합(Union)으로 통합하여 검색 다양성을 확보합니다. 단일 엔진에서 놓친 결과를 다른 엔진이 보완합니다.

Reciprocal Rank Fusion

각 엔진의 절대 점수 대신 랭킹 순위를 기반으로 결합하기 때문에 스코어 스케일 차이에 영향을 받지 않고 안정적이고 일관된 최종 랭킹을 생성합니다.

Query Lab

Query Lab은 검색 결과를 단계별로 해부하고 알고리즘 변경의 효과를 실험할 수 있는 인터랙티브 분석 도구입니다. 단순히 최종 결과만 보는 것이 아니라, 각 검색 엔진이 어떤 후보를 어떤 이유로 추천했는지, Fusion 이후 랭킹이 어떻게 변화했는지를 단계별로 시각화합니다. 이를 통해 검색 알고리즘의 투명성을 높이고, 문제 발생 시 빠르게 원인을 파악할 수 있습니다.



Engine Retrieval 분석

각 검색 엔진(CLIP, SBERT 등)이 독립적으로 반환한 결과를 비교 분석합니다. 어떤 엔진이 어떤 쿼리 유형에 강한지 파악할 수 있습니다.



Engine Contribution 분석

최종 랭킹에서 각 검색 엔진이 차지하는 기여 비율을 정량적으로 측정합니다. 특정 엔진에 과도하게 의존하고 있는지 진단할 수 있습니다.



Candidate Pool 분석

복수 엔진의 결과를 통합한 후보군의 구성을 분석합니다. 각 엔진의 기여 비율과 중복 포함 여부를 시각적으로 확인할 수 있습니다.



Ablation 실험

특정 검색 엔진이나 Fusion 전략을 제거했을 때의 품질 변화를 측정하는 실험입니다. 각 구성 요소의 필요성과 효과를 검증하는 데 사용됩니다.



Hybrid Fusion 분석

RRF(Reciprocal Rank Fusion) 적용 전후의 랭킹 변화를 추적합니다. 어떤 결과가 Fusion으로 순위가 올라갔는지, 내려갔는지 확인합니다.

Quality Monitor

Quality Monitor는 Streamlit 기반으로 구축된 Search Operations Dashboard입니다. 검색 실험의 결과를 기록하고 비교하는 것은 물론, 운영 환경에서 발생하는 다양한 시스템 지표를 실시간으로 추적합니다. 실험 환경과 운영 환경을 하나의 인터페이스에서 통합 관리함으로써 의사결정의 속도와 정확성을 높입니다.

검색 실험 결과 기록

알고리즘 변경, 파라미터 조정, 모델 교체 등 각 실험의 설정과 결과를 체계적으로 저장하고 버전 관리합니다. 이전 실험과의 비교가 용이합니다.

검색 결과 수 기록

쿼리 유형별로 반환되는 검색 결과 수를 추적합니다. 결과 수가 비정상적으로 적거나 많은 경우를 감지하여 시스템 이상을 조기에 진단합니다.

Latency 모니터링

검색 요청별 응답 시간을 실시간으로 수집하고 시각화합니다. P50, P95, P99 분위수 기반으로 이상 지연을 탐지하고 알림을 발생시킵니다.

KPI 분석

Hit@K, Mean Rank 등 핵심 검색 품질 지표를 시간 흐름에 따라 추적합니다. 실험 변경이 KPI에 미치는 영향을 직관적인 차트로 확인할 수 있습니다.

왜 통합 대시보드인가?

검색 실험 결과와 운영 데이터가 분리된 환경에서는 실험 효과를 실제 운영 지표와 연결하기 어렵습니다. Quality Monitor는 이 두 가지를 하나의 뷰에 통합함으로써:

- 실험 변경이 레이턴시에 미치는 영향을 즉시 파악
- 품질 개선과 성능 트레이드오프를 동시에 평가
- 팀 전체가 동일한 데이터 기반으로 의사결정
- 운영 이슈와 실험 이슈를 하나의 컨텍스트에서 디버깅

Streamlit을 선택한 이유는 빠른 프로토타이핑이 가능하고, Python 기반 검색 시스템과의 통합이 용이하며, 별도 프론트엔드 개발 없이도 인터랙티브한 대시보드를 구축할 수 있기 때문입니다.


Search Evaluation Framework

검색 품질을 검증하기 위해 Intent Query 기반 평가 파이프라인을 구축했습니다. 사용자의 실제 검색 의도를 반영한 쿼리셋을 설계하고, 이를 통해 Hybrid Retrieval 적용 전후의 품질 변화를 정량적으로 측정했습니다.

평가 지표 정의

1 Hit@1 상위 1개 결과 안에 정답이 포함되는 비율. 사용자가 첫 번째 결과만 보는 경우의 정확도를 측정합니다.	2 Hit@5 상위 5개 결과 안에 정답이 포함되는 비율. 사용자가 결과 페이지 첫 화면을 스캔하는 시나리오를 반영합니다.
3 Hit@10 상위 10개 결과 안에 정답이 포함되는 비율. 넓은 범위의 검색 커버리지를 평가합니다.	4 Mean Rank 정답 결과의 평균 랭킹 순위. 낮을수록 정답이 상위에 랭크되어 있음을 의미합니다.

평가 결과 비교



Hybrid Retrieval 적용 이후 Hit@1이 0.90에서 **1.00**으로 완전 개선되었으며, Mean Rank 역시 1.30에서 **1.00**으로 안정화되었습니다.

이는 첫 번째 결과에서 정답을 반환하는 정확도가 100%에 도달했음을 의미합니다.

What I Learned

MovieFactory 프로젝트는 단순한 기능 구현을 넘어, 검색 시스템을 **Search Quality Lifecycle** 관점에서 설계하는 경험을 제공했습니다. 검색 엔진을 만드는 것과 검색 품질을 관리하는 것은 본질적으로 다른 문제임을 이 프로젝트를 통해 깊이 이해하게 되었습니다.

Hybrid Retrieval System 설계

단일 모델의 한계를 극복하기 위해 CLIP과 SBERT를 결합하고 RRF로 통합하는 파이프라인을 설계했습니다. 각 모델의 특성을 이해하고 상호 보완적으로 결합하는 방법을 익혔습니다.

Search Experiment Framework 구축

알고리즘 변경의 효과를 체계적으로 검증하는 실험 환경을 구축함으로써, 직관이 아닌 데이터 기반으로 검색 품질을 개선하는 사이클을 경험했습니다.

Search Ranking Explainability 분석

왜 특정 결과가 상위에 랭크되었는지 설명할 수 있는 구조를 만드는 것이 검색 시스템 신뢰성의 핵심임을 깨달았습니다. Query Lab을 통해 랭킹의 투명성을 확보했습니다.


Search Operations Monitoring 경험

실험 결과와 운영 지표를 통합 모니터링하는 대시보드를 구축함으로써, 검색 시스템의 건강 상태를 지속적으로 관찰하고 개선하는 운영 사이클을 이해했습니다.

- ❑ **핵심 인사이트:** 검색 시스템은 만드는 것보다 *지속적으로 측정하고 개선하는 것*이 더 중요합니다. MovieFactory는 그 라이프사이클 전체를 아우르는 플랫폼으로 설계되었습니다.

Closing

MovieFactory Demo



실제 서비스 운영에서는 기능을 만드는 것보다 문제가 발생했을 때 원인을 분석하고 개선하는 과정이 더 중요하다고 생각합니다.

Customer Insight
Problem Analysis
Data-driven improvement

Closing Message

CS 업무에서 고객 문제를 직접 접하면서
문제를 직관이 아니라 데이터로 분석하는 방식에 관심을 갖게 되었고

MovieFactory 프로젝트에서는 단순한 검색 기능 구현 프로젝트가 아니라
검색 결과를 분석하고 실험을 통해 개선할 수 있는 Search
Experiment Platform으로 설계되었습니다.

Query Lab을 통해 검색 결과 랭킹 구조를 분석하고,
Evaluation과 실험 환경을 통해 알고리즘 변경의 효과를 데이터 기반으로
검증했으며,
Quality Monitor를 통해 실험 결과와 운영 지표를 함께 관찰할 수 있는
구조를 만들었습니다.

이 프로젝트를 통해 서비스 문제를 직관이 아니라 데이터로 분석하고 실험
을 통해 개선을 검증하는 서비스 개선 사이클을 경험했습니다.

감사합니다.